

**LAPORAN PRAKTIKUM KECERDASAN BUATAN
TUGAS MANDIRI**

**KLASIFIKASI OTOMATIS TINGKAT PRIORITAS TIKET
LAYANAN TI MENGGUNAKAN MULTINOMIAL NAIVE
BAYES**

(Studi Kasus: IT Helpdesk Kampus)

Bidang AI: Machine Learning

[Logo Institusi]

Disusun oleh:

[Nama Mahasiswa]

NIM: [Nomor Induk Mahasiswa]

Repositori: [github.com/\[username-anda\]/klasifikasi-prioritas-tiket-ti](https://github.com/[username-anda]/klasifikasi-prioritas-tiket-ti)

**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS [NAMA FAKULTAS]
[NAMA INSTITUSI]**

2026

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat-Nya laporan praktikum Kecerdasan Buatan ini dapat diselesaikan. Laporan ini disusun untuk memenuhi tugas mandiri, dengan topik klasifikasi otomatis tingkat prioritas tiket layanan TI menggunakan algoritme *Multinomial Naive Bayes*.

Dalam mengerjakan praktikum, penulis belajar bahwa membangun model hanyalah sebagian kecil pekerjaan. Bagian yang lebih menantang adalah merumuskan masalah dengan jelas, menyadari batas data yang dipakai, dan menimbang dampak etika dari sistem yang dibuat. Penulis berusaha menuliskan semua itu apa adanya, termasuk kelemahan dataset simulasi dan hasil yang tidak sepenuhnya sempurna.

Penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah yang telah memberikan arahan, serta kepada rekan-rekan yang bersedia berdiskusi selama pengerjaan. Penulis menyadari laporan ini masih memiliki kekurangan, sehingga kritik dan saran yang membangun sangat diharapkan.

[Kota], [tanggal] 2026

Penulis

ABSTRAK

Penentuan tingkat prioritas tiket pada layanan bantuan TI (*IT helpdesk*) yang dilakukan manual bersifat subjektif dan melambat ketika tiket menumpuk. Praktikum ini membangun model *machine learning* untuk mengklasifikasikan teks tiket ke tiga kelas prioritas, yaitu Rendah, Sedang, dan Tinggi.

Model yang digunakan adalah *Multinomial Naive Bayes* dengan representasi TF-IDF (unigram dan bigram), dilatih pada 200 tiket simulasi berbahasa Indonesia menggunakan Python di Google Colab. Sistem dirancang dengan nilai kepercayaan, ambang 0,70, aturan kata kunci keamanan, dan peninjauan petugas agar keputusan otomatis tetap diawasi manusia.

Hasil evaluasi menunjukkan akurasi 97,5% pada data uji (40 tiket) dan rerata 93,5% pada validasi silang 5 lipatan. Perbandingan dengan *Logistic Regression* dan *Linear SVM* memberi hasil serupa sehingga pada data ini pilihan algoritme tidak menentukan. Analisis kesalahan menunjukkan model lemah pada tiket yang maknanya bergantung konteks, dan dapat salah dengan keyakinan tinggi pada kasus baru seperti dugaan serangan siber. Karena datanya simulasi, hasil tidak dapat langsung digeneralisasi ke data nyata. Laporan juga membahas manfaat, keterbatasan, serta risiko etika dan privasi beserta mitigasinya.

Kata kunci: kecerdasan buatan, *machine learning*, klasifikasi teks, *Naive Bayes*, tiket helpdesk, etika data

DAFTAR ISI

BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Identifikasi Masalah.....	2
1.3 Rumusan Masalah.....	2
1.4 Tujuan Praktikum.....	2
1.5 Batasan Masalah.....	3
1.6 Manfaat Praktikum.....	3
1.7 Sistematika Penulisan.....	3
BAB II LANDASAN TEORI.....	4
2.1 Kecerdasan Buatan dan Bidang-Bidanganya.....	4
2.2 Machine Learning.....	5
2.3 Klasifikasi Teks dan Pemrosesan Bahasa.....	5
2.4 Algoritme Multinomial Naive Bayes.....	6
2.5 Metrik Evaluasi.....	7
2.6 Manajemen Tiket dan Penentuan Prioritas.....	8
2.7 Etika, Privasi, dan Tata Kelola Data.....	8
2.8 Posisi Praktikum terhadap Pendekatan Lain.....	9
BAB III ANALISIS KEBUTUHAN DAN PERANCANGAN SOLUSI.....	10
3.1 Judul dan Bidang AI yang Dipilih.....	10
3.2 Deskripsi dan Analisis Masalah.....	10
3.3 Alasan Pemilihan Bidang Machine Learning.....	11
3.4 Data dan Masukan yang Diperlukan.....	11
3.5 Definisi Kelas Prioritas.....	12
3.6 Arsitektur dan Alur Kerja Solusi.....	12
3.7 Alur Keputusan dengan Keterlibatan Petugas.....	13
3.8 Lingkungan Pengembangan.....	14
3.9 Rancangan Evaluasi.....	14
BAB IV IMPLEMENTASI, HASIL, DAN PEMBAHASAN.....	15
4.1 Dataset Tiket.....	15
4.2 Pra-pemrosesan Teks.....	16
4.3 Pembagian Data dan Pelatihan Model.....	17
4.4 Hasil Evaluasi pada Data Uji.....	17
4.5 Validasi Silang 5 Lipatan.....	18
4.6 Pengaruh Parameter Penghalusan (α).....	18

4.7 Pengaruh Rentang N-gram.....	19
4.8 Perbandingan dengan Algoritme Lain.....	20
4.9 Fitur yang Paling Berpengaruh.....	20
4.10 Analisis Kesalahan.....	21
4.11 Pengaruh Ambang Kepercayaan.....	21
4.12 Demonstrasi Prediksi pada Tiket Baru.....	22
4.13 Pembahasan.....	23
BAB V MANFAAT, KETERBATASAN, DAN RISIKO ETIKA/PRIVASI..	24
5.1 Manfaat.....	24
5.2 Keterbatasan.....	24
5.3 Risiko Etika dan Privasi.....	25
5.4 Rekomendasi Tata Kelola.....	26
5.5 Rencana Penerapan Bertahap.....	27
BAB VI KESIMPULAN DAN SARAN.....	28
6.1 Kesimpulan.....	28
6.2 Saran.....	28
DAFTAR PUSTAKA.....	29
LAMPIRAN A KODE PROGRAM LENGKAP.....	30
LAMPIRAN B CUPLIKAN DATASET TAMBAHAN.....	32
LAMPIRAN C NASKAH PRESENTASI 5–7 MENIT.....	33
LAMPIRAN D DAFTAR PERIKSA KESESUAIAN DENGAN PETUNJUK TUGAS.....	35
LAMPIRAN E PANDUAN MENJALANKAN DAN TAUTAN REPOSITORI.....	35

DAFTAR TABEL

Tabel 2.1 Ringkasan bidang AI, karakteristik, dan contoh penerapannya di bidang STI.....	4
Tabel 2.2 Contoh perhitungan Naive Bayes untuk tiket "server down" ($\alpha = 1$).....	7
Tabel 2.3 Matriks dampak dan urgensi yang disederhanakan menjadi tiga prioritas	8
Tabel 3.1 Perbandingan proses pemilahan tiket: kondisi saat ini dan usulan.....	10
Tabel 3.2 Pertimbangan pemilihan bidang AI untuk studi kasus prioritas tiket....	11
Tabel 3.3 Bidang data tiket dan perannya dalam sistem.....	11
Tabel 3.4 Definisi dan kriteria kelas prioritas.....	12
Tabel 3.5 Lingkungan dan pustaka yang digunakan.....	14
Tabel 4.1 Cuplikan sembilan tiket dari dataset.....	15
Tabel 4.2 Metrik per kelas pada data uji ($n = 40$).....	17
Tabel 4.3 Akurasi tiap lipatan pada validasi silang berlapis.....	18
Tabel 4.4 Akurasi validasi silang untuk berbagai nilai α	19
Tabel 4.5 Perbandingan rentang n-gram (Naive Bayes, $\alpha = 0,1$).....	19
Tabel 4.6 Perbandingan tiga algoritme dengan fitur TF-IDF yang sama.....	20
Tabel 4.7 Cakupan otomatisasi dan akurasi pada berbagai ambang kepercayaan (data uji).....	21
Tabel 4.8 Hasil prediksi pada enam tiket baru.....	22
Tabel 5.1 Keterbatasan solusi dan dampaknya.....	24
Tabel 5.2 Risiko dan langkah mitigasi.....	26
Tabel B.1 Empat belas tiket pertama dalam dataset.....	32
Tabel C.1 Rencana presentasi dan alokasi waktu.....	33
Tabel D.1 Pemetaan unsur laporan yang diminta terhadap isi laporan.....	35

DAFTAR GAMBAR

Gambar 3.1 Alur pipeline klasifikasi prioritas tiket.....	13
Gambar 3.2 Alur keputusan sistem dengan peninjauan manusia.....	13
Gambar 4.1 Distribusi kelas prioritas pada dataset.....	15
Gambar 4.2 Confusion matrix pada data uji.....	18
Gambar 4.3 Akurasi rata-rata validasi silang terhadap nilai α	19
Gambar 4.4 Fitur (kata/bigram) paling khas untuk tiap kelas.....	20

BAB I PENDAHULUAN

1.1 Latar Belakang

Layanan teknologi informasi di perguruan tinggi hari ini bukan lagi sekadar pelengkap. Pengisian kartu rencana studi, perkuliahan daring, ujian berbasis komputer, perpustakaan digital, sampai presensi semuanya bergantung pada jaringan dan sistem yang harus tersedia hampir sepanjang waktu. Ketika salah satu komponen bermasalah, dampaknya langsung terasa: mahasiswa gagal mengisi KRS di hari terakhir, dosen tidak dapat mengunggah nilai, atau kelas praktikum tertunda karena komputer laboratorium tidak bisa terhubung ke jaringan.

Unit layanan bantuan TI (*IT helpdesk*) berada di garis depan untuk menangani semua keluhan tersebut. Pengguna melaporkan masalahnya melalui formulir, surel, atau aplikasi tiket, lalu laporan itu dicatat sebagai tiket. Masalahnya, tiket yang masuk tidak sama bobotnya. Laporan bahwa server SIAKAD tidak dapat diakses oleh seluruh mahasiswa jelas jauh lebih mendesak daripada permintaan mengganti foto profil. Namun, di banyak unit layanan, penentuan tingkat prioritas ini masih dikerjakan manual oleh petugas yang membaca tiket satu per satu.

Cara manual punya beberapa kelemahan yang wajar terjadi. Pertama, keputusan sangat bergantung pada pengalaman dan kondisi petugas pada saat itu, sehingga dua petugas bisa memberi prioritas berbeda untuk tiket yang hampir sama. Kedua, pada periode sibuk seperti masa registrasi atau ujian, tiket menumpuk dan tiket genting berisiko tenggelam di antara tiket rutin. Ketiga, waktu yang dipakai untuk memilah tiket adalah waktu yang seharusnya bisa dipakai untuk menyelesaikan masalah itu sendiri.

Kecerdasan buatan, khususnya *machine learning*, menawarkan jalan keluar yang cukup masuk akal untuk persoalan ini. Deskripsi keluhan pada tiket adalah teks, dan teks tersebut membawa petunjuk yang konsisten tentang tingkat keparahan: kata seperti *seluruh*, *semua*, *down*, atau *tidak bisa diakses* biasanya muncul pada gangguan luas, sedangkan kata seperti *minta*, *panduan*, atau *tanya* biasanya muncul pada permintaan layanan. Pola semacam ini dapat dipelajari dari tiket-tiket historis yang sudah diberi label prioritas oleh petugas berpengalaman.

Berdasarkan pertimbangan tersebut, praktikum ini memilih bidang *Machine Learning* dengan studi kasus klasifikasi otomatis tingkat prioritas tiket layanan TI di lingkungan kampus. Algoritme yang digunakan adalah *Multinomial Naive Bayes* yang dipadukan dengan pembobotan TF-IDF. Pilihan ini sengaja sederhana agar

hasilnya mudah dijelaskan, cepat dilatih pada data kecil, dan cocok didemonstrasikan menggunakan Google Colab. Sistem ini dirancang sebagai alat bantu keputusan, bukan pengganti petugas, dan aspek keterbatasan serta etikanya dibahas tersendiri pada Bab V.

1.2 Identifikasi Masalah

Dari uraian latar belakang, penulis mengidentifikasi beberapa masalah yang menjadi titik tolak praktikum ini:

- Penentuan prioritas tiket masih bersifat subjektif dan dapat berbeda antarpetugas.
- Volume tiket yang tinggi pada periode tertentu memperlambat proses pemilahan dan meningkatkan risiko tiket kritis terlambat ditangani.
- Belum ada mekanisme yang memberi tahu petugas seberapa yakin sebuah keputusan prioritas, sehingga tiket yang ambigu tidak mendapat perhatian khusus.
- Belum ada kerangka yang jelas untuk memastikan bahwa otomatisasi tidak melanggar privasi pengguna maupun menimbulkan bias dalam pelayanan.

1.3 Rumusan Masalah

Masalah-masalah di atas dirumuskan menjadi tiga pertanyaan berikut.

1. Bagaimana merancang alur sistem yang mampu mengklasifikasikan tingkat prioritas tiket layanan TI dari teks deskripsi keluhan menggunakan pendekatan *machine learning*?
2. Seberapa baik kinerja algoritme *Multinomial Naive Bayes* dengan representasi TF-IDF dalam memisahkan tiket ke kelas prioritas Rendah, Sedang, dan Tinggi, dan di mana letak kesalahannya?
3. Apa saja manfaat, keterbatasan, serta risiko etika dan privasi dari penerapan sistem ini pada layanan TI institusi?

1.4 Tujuan Praktikum

1. Mengidentifikasi karakteristik bidang kecerdasan buatan dan menjelaskan alasan *machine learning* dipilih untuk studi kasus ini.
2. Membangun dan mengevaluasi model klasifikasi prioritas tiket menggunakan Python di Google Colab.

3. Menganalisis hasil model, termasuk contoh kesalahan prediksi, untuk menilai kelayakannya sebagai alat bantu petugas.
4. Menyusun analisis manfaat, keterbatasan, dan risiko etika/privasi beserta langkah mitigasinya.

1.5 Batasan Masalah

- Bidang AI yang dibahas dibatasi pada *machine learning* terawasi (*supervised learning*) untuk klasifikasi teks.
- Data yang digunakan adalah 200 tiket simulasi berbahasa Indonesia yang disusun penulis mengikuti pola keluhan layanan TI kampus. Data ini bukan data nyata dari institusi mana pun.
- Kelas prioritas dibatasi pada tiga tingkat: Rendah, Sedang, dan Tinggi.
- Sistem hanya memprediksi prioritas. Penentuan kategori masalah, penugasan teknisi, dan penyelesaian tiket berada di luar cakupan.
- Demonstrasi dilakukan pada lingkungan Python (Google Colab) dan belum diintegrasikan ke aplikasi tiket sungguhan.

1.6 Manfaat Praktikum

Bagi penulis, praktikum ini menjadi latihan menyeluruh mulai dari merumuskan masalah, menyiapkan data, membangun model, sampai menilai dampaknya secara kritis. Bagi pembaca, khususnya rekan mahasiswa Sistem dan Teknologi Informasi, laporan ini dapat dipakai sebagai contoh sederhana penerapan klasifikasi teks. Bagi unit layanan TI, hasil praktikum memberi gambaran awal tentang apa yang bisa dan tidak bisa diharapkan dari otomatisasi pemilahan tiket.

1.7 Sistematika Penulisan

Laporan ini terdiri atas enam bab. Bab I memuat latar belakang, rumusan masalah, tujuan, batasan, dan manfaat. Bab II membahas landasan teori mengenai bidang AI, *machine learning*, klasifikasi teks, algoritme *Naive Bayes*, metrik evaluasi, manajemen tiket, dan etika data. Bab III menguraikan analisis kebutuhan dan rancangan solusi. Bab IV menyajikan implementasi, hasil eksperimen, dan pembahasan. Bab V membahas manfaat, keterbatasan, serta risiko etika dan privasi. Bab VI berisi kesimpulan dan saran. Bagian akhir memuat daftar pustaka dan lampiran berupa kode lengkap, cuplikan data, naskah presentasi, dan daftar Periksa kesesuaian tugas.

BAB II LANDASAN TEORI

2.1 Kecerdasan Buatan dan Bidang-Bidangnya

Kecerdasan buatan (*Artificial Intelligence*, AI) secara umum dipahami sebagai cabang ilmu komputer yang mempelajari cara membuat mesin melakukan pekerjaan yang biasanya membutuhkan kecerdasan manusia, seperti mengenali pola, memahami bahasa, mengambil keputusan, dan belajar dari pengalaman (Russell & Norvig, 2021). AI bukan satu teknik tunggal, melainkan payung bagi banyak bidang dengan pendekatan dan karakter masalah yang berbeda-beda. Sebelum memilih bidang untuk studi kasus, penulis meninjau kesepuluh bidang yang ditawarkan pada petunjuk tugas. Ringkasannya disajikan pada Tabel 2.1.

Tabel 2.1 Ringkasan bidang AI, karakteristik, dan contoh penerapannya di bidang STI

Bidang AI	Karakteristik utama	Contoh penerapan STI
Machine Learning	Belajar pola dari data untuk prediksi tanpa aturan yang ditulis manual	Prioritas tiket, deteksi spam, prediksi churn
Deep Learning	Jaringan saraf berlapis banyak; kuat untuk data besar dan tidak terstruktur	Deteksi anomali log, pengenalan suara
Natural Language Processing	Memproses dan memahami bahasa manusia	Chatbot layanan akademik, analisis sentimen
Computer Vision	Mengekstrak informasi dari citra dan video	Pengenalan plat nomor, presensi wajah
Sistem Pakar	Menerapkan aturan dan pengetahuan pakar secara eksplisit	Diagnosis gangguan jaringan berbasis aturan
Logika Fuzzy	Menangani nilai yang tidak tegas dengan derajat keanggotaan	Kendali suhu ruang server
Pencarian dan Optimasi	Mencari solusi terbaik dalam ruang kemungkinan	Penjadwalan kuliah, penempatan server
Sistem Rekomendasi	Menyarankan item berdasarkan preferensi dan perilaku	Rekomendasi mata kuliah, bahan belajar
Agen Cerdas	Entitas yang mengamati lingkungan dan bertindak untuk mencapai tujuan	Asisten virtual, otomasi operasi TI
Robotika dan Sistem Otonom	Menggabungkan sensor, kendali, dan aksi pada perangkat fisik	Robot pengantar, sistem parkir otonom

Dari tabel tersebut terlihat bahwa persoalan penentuan prioritas tiket bersifat prediktif dan berbasis teks. Data historis berlabel tersedia atau dapat disiapkan, sementara aturan pemilahnya sulit dituliskan lengkap secara manual. Karakter

inilah yang mengarahkan penulis pada *machine learning*, dengan komponen pemrosesan bahasa sederhana untuk mengubah teks menjadi angka.

2.2 Machine Learning

Machine learning (ML) adalah pendekatan di mana program meningkatkan kinerjanya pada suatu tugas melalui pengalaman, yaitu data (Mitchell, 1997). Alih-alih menulis aturan "jika kata X muncul maka prioritas tinggi" satu per satu, pengembang menyediakan contoh masukan beserta jawaban yang benar, dan algoritme menyimpulkan sendiri hubungan di antara keduanya.

Secara garis besar, ML dibagi menjadi tiga paradigma. Pada *supervised learning*, data latih memiliki label sehingga model belajar memetakan masukan ke label tersebut; contohnya klasifikasi dan regresi. Pada *unsupervised learning*, data tidak berlabel dan model mencari struktur tersembunyi seperti kelompok (*clustering*). Pada *reinforcement learning*, agen belajar melalui percobaan dan menerima imbalan atau hukuman dari lingkungannya. Studi kasus dalam laporan ini termasuk *supervised learning* jenis klasifikasi karena setiap tiket historis memiliki label prioritas.

Tahapan kerja proyek ML yang lazim adalah: merumuskan masalah, mengumpulkan dan membersihkan data, merepresentasikan data menjadi fitur, memilih dan melatih model, mengevaluasi pada data yang tidak dipakai saat pelatihan, lalu memantau dan memperbarui model setelah dipakai. Urutan ini menjadi kerangka rancangan pada Bab III.

2.3 Klasifikasi Teks dan Pemrosesan Bahasa

Klasifikasi teks adalah tugas menentukan kelas dari sebuah dokumen berdasarkan isinya. Penyaring spam adalah contoh paling dikenal, dan Manning, Raghavan, dan Schütze (2008) membahas *Naive Bayes* sebagai salah satu metode dasar untuk tugas ini. Tiket layanan TI dapat diperlakukan sebagai dokumen pendek, dan prioritasnya sebagai kelas.

Pra-pemrosesan teks

Teks mentah perlu dirapikan sebelum diolah. Langkah yang dipakai dalam praktikum ini adalah *case folding* (mengubah semua huruf menjadi huruf kecil), pembersihan karakter selain huruf dan angka, tokenisasi (memecah kalimat menjadi kata), dan penghapusan *stopword* (kata umum yang tidak membedakan kelas, misalnya *di*, *yang*, dan *untuk*). Penulis tidak menerapkan *stemming* karena bentuk

kata seperti *mati* dan *lambat* sudah cukup informatif, dan *stemmer* bahasa Indonesia dapat mengubah kata teknis menjadi bentuk yang membingungkan.

Representasi bag-of-words dan n-gram

Model ML membutuhkan angka, bukan kalimat. Pendekatan *bag-of-words* mengubah setiap dokumen menjadi vektor yang menghitung kemunculan tiap kata dalam kosakata, dengan mengabaikan urutan kata. Untuk menangkap sedikit konteks, dapat digunakan *n-gram*, yaitu gabungan n kata berurutan. Misalnya bigram "tidak bisa" membawa makna yang berbeda dari kata "tidak" dan "bisa" yang dipisah.

Pembobotan TF-IDF

Frekuensi mentah kurang adil karena kata yang muncul di hampir semua tiket tidak banyak membantu membedakan kelas. TF-IDF (*term frequency-inverse document frequency*) memberi bobot lebih besar pada kata yang sering muncul pada suatu dokumen tetapi jarang muncul di dokumen lain. Bobot sebuah kata t pada dokumen d dihitung sebagai berikut.

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \text{idf}(t), \text{ dengan } \text{idf}(t) = \ln((1 + N) / (1 + \text{df}(t))) + 1$$

Di sini N adalah jumlah dokumen dan $\text{df}(t)$ adalah jumlah dokumen yang memuat kata t . Bentuk idf di atas adalah varian dengan penghalusan yang dipakai pustaka *scikit-learn* (Pedregosa dkk., 2011). Praktikum ini juga mengaktifkan *sublinear tf*, yaitu mengganti tf dengan $1 + \ln(\text{tf})$ agar kata yang berulang banyak kali tidak mendominasi.

2.4 Algoritme Multinomial Naive Bayes

Naive Bayes adalah keluarga pengklasifikasi probabilistik yang bertumpu pada Teorema Bayes. Untuk dokumen d dan kelas c , teorema tersebut menyatakan bahwa peluang kelas setelah melihat dokumen sebanding dengan peluang awal kelas dikalikan peluang dokumen jika kelas itu benar.

$$P(c | d) \propto P(c) \times \prod P(w_i | c)$$

Kata "naif" muncul karena algoritme mengasumsikan setiap kata pada dokumen saling bebas apabila kelasnya diketahui. Asumsi ini jelas tidak sepenuhnya benar untuk bahasa alami, tetapi dalam praktik klasifikasi teks algoritme ini sering tetap bekerja baik dan sangat cepat dilatih. Pada varian multinomial, $P(w | c)$ diestimasi dari frekuensi kata w di seluruh dokumen kelas c dengan penghalusan Laplace (*Laplace/additive smoothing*).

$$P(w | c) = (\text{count}(w, c) + \alpha) / (\text{total kata kelas } c + \alpha \times |V|)$$

Parameter α mencegah peluang nol untuk kata yang belum pernah muncul pada suatu kelas, dan $|V|$ adalah ukuran kosakata. Nilai $\alpha = 1$ adalah penghalusan Laplace klasik, sementara nilai yang lebih kecil membuat model lebih percaya pada data latih.

Contoh perhitungan sederhana

Agar lebih konkret, misalkan kosakata hanya enam kata: server, down, printer, macet, password, reset ($|V| = 6$). Pada data latih kelas Tinggi, kata server muncul 3 kali, down 3 kali, password 1 kali, dan reset 1 kali, sehingga totalnya 8 kata. Pada kelas Rendah, printer muncul 1 kali, password 3 kali, dan reset 3 kali, total 7 kata. Kedua kelas dianggap memiliki peluang awal yang sama, 0,5. Dengan $\alpha = 1$, sebuah tiket baru berisi "server down" dihitung sebagai berikut.

Tabel 2.2 Contoh perhitungan Naive Bayes untuk tiket "server down" ($\alpha = 1$)

Kelas	$P(\text{server} c)$	$P(\text{down} c)$	$P(c) \times \text{hasil kali}$	Peluang akhir
Tinggi	$4/14 = 0,2857$	$4/14 = 0,2857$	$0,5 \times 0,0816 = 0,0408$	0,932
Rendah	$1/13 = 0,0769$	$1/13 = 0,0769$	$0,5 \times 0,0059 = 0,0030$	0,068

Peluang akhir diperoleh dengan menormalkan kedua nilai sehingga jumlahnya 1. Hasilnya, tiket "server down" diklasifikasikan sebagai Tinggi dengan keyakinan sekitar 93%. Pada implementasi sebenarnya perhitungan dilakukan dalam bentuk logaritma untuk menghindari angka yang terlalu kecil, dan fitur yang dipakai adalah bobot TF-IDF, bukan hitungan bulat, tetapi logikanya sama.

2.5 Metrik Evaluasi

Model dinilai pada data uji yang tidak dipakai selama pelatihan. Empat metrik utama yang dipakai adalah sebagai berikut.

- **Akurasi:** proporsi prediksi yang benar dari seluruh prediksi.
- **Presisi** kelas c : dari semua tiket yang diprediksi kelas c , berapa yang benar-benar kelas c .
- **Recall** kelas c : dari semua tiket yang sebenarnya kelas c , berapa yang berhasil terdeteksi.
- **F1-score:** rerata harmonik presisi dan recall, $F1 = 2 \times (\text{presisi} \times \text{recall}) / (\text{presisi} + \text{recall})$.

Confusion matrix memperlihatkan pasangan label sebenarnya dan prediksi sehingga jenis kesalahan tampak jelas. Untuk data yang jumlah kelasnya seimbang, akurasi sudah cukup informatif, tetapi rerata makro (*macro average*) tetap dilaporkan agar setiap kelas dihitung setara. Selain pembagian latih-uji tunggal, digunakan juga validasi silang berlapis 5 lipatan (*stratified 5-fold cross-validation*) supaya penilaian tidak bergantung pada satu pembagian data yang kebetulan mudah atau sulit.

Dalam konteks helpdesk, tidak semua kesalahan sama beratnya. Tiket Tinggi yang diprediksi Rendah (*under-triage*) jauh lebih berbahaya daripada tiket Rendah yang diprediksi Tinggi (*over-triage*), sebab yang pertama menunda penanganan gangguan serius. Karena itu analisis kesalahan pada Bab IV tidak berhenti pada angka akurasi.

2.6 Manajemen Tiket dan Penentuan Prioritas

Dalam praktik manajemen layanan TI, misalnya kerangka ITIL (AXELOS, 2019), prioritas insiden lazim ditentukan dari dua pertimbangan: dampak (seberapa banyak pengguna atau proses bisnis yang terpengaruh) dan urgensi (seberapa cepat masalah harus diselesaikan). Kombinasi keduanya menghasilkan tingkat prioritas yang kemudian menentukan target waktu respons dan penyelesaian.

Tabel 2.3 Matriks dampak dan urgensi yang disederhanakan menjadi tiga prioritas

Dampak \ Urgensi	Mendesak	Biasa	Tidak mendesak
Luas (banyak pengguna/layanan inti)	Tinggi	Tinggi	Sedang
Sedang (satu unit/kelompok)	Tinggi	Sedang	Rendah
Kecil (satu pengguna)	Sedang	Rendah	Rendah

Matriks tersebut menunjukkan bahwa label prioritas sebenarnya adalah hasil pertimbangan manusia atas dampak dan urgensi. Model ML tidak menghitung dampak secara eksplisit. Ia hanya menirunya lewat petunjuk yang tersirat dalam teks, seperti kata *seluruh* atau *semua* untuk dampak luas. Pemahaman ini penting agar hasil model tidak dianggap lebih pasti daripada yang sebenarnya.

2.7 Etika, Privasi, dan Tata Kelola Data

Tiket layanan sering memuat data pribadi tanpa disengaja: nama, nomor induk, alamat surel, bahkan kata sandi yang ditempelkan pengguna saat meminta bantuan. Di Indonesia, pemrosesan data pribadi diatur dalam Undang-Undang

Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi. Beberapa prinsip yang relevan bagi praktikum ini adalah pembatasan tujuan (data dipakai sesuai tujuan awal), minimisasi data (hanya mengambil yang perlu), dan keamanan data.

Dari sisi etika AI, tiga hal menjadi perhatian: keadilan (apakah kelompok pengguna tertentu diperlakukan tidak setara), transparansi (apakah keputusan dapat dijelaskan), dan akuntabilitas (siapa yang bertanggung jawab bila keputusan keliru). Algoritme *Naive Bayes* relatif unggul dari sisi transparansi karena kontribusi tiap kata dapat ditelusuri langsung dari parameter model.

2.8 Posisi Praktikum terhadap Pendekatan Lain

Penentuan prioritas tiket sebenarnya juga dapat didekati dengan sistem berbasis aturan atau sistem pakar, atau dengan model bahasa berukuran besar. Aturan kata kunci mudah dibuat tetapi rapuh terhadap variasi bahasa dan sulit dirawat saat jumlah aturan membengkak. Model bahasa besar lebih fleksibel tetapi membutuhkan sumber daya, biaya, dan pertimbangan privasi yang jauh lebih besar bila data tiket harus dikirim ke layanan pihak ketiga. *Naive Bayes* dengan TF-IDF berada di tengah: belajar dari data, ringan, dan dapat dijalankan sepenuhnya di lingkungan institusi. Praktikum ini memakainya sebagai *baseline* yang jujur, sekaligus membandingkannya dengan dua algoritme linear lain pada Bab IV.

BAB III ANALISIS KEBUTUHAN DAN PERANCANGAN SOLUSI

3.1 Judul dan Bidang AI yang Dipilih

Judul yang dipilih untuk praktikum ini adalah "**Klasifikasi Otomatis Tingkat Prioritas Tiket Layanan TI Menggunakan Multinomial Naive Bayes (Studi Kasus: IT Helpdesk Kampus)**". Bidang AI yang dipilih adalah *Machine Learning*, tepatnya *supervised learning* untuk klasifikasi teks, dengan bantuan teknik pemrosesan bahasa alami tingkat dasar untuk pra-pemrosesan dan representasi fitur.

3.2 Deskripsi dan Analisis Masalah

Sebuah helpdesk kampus rata-rata menerima tiket dari beberapa kelompok pengguna: mahasiswa, dosen, tenaga kependidikan, dan pimpinan. Isi tiket ditulis bebas oleh pengguna, sehingga panjangnya bervariasi dan gayanya tidak seragam. Ada yang menulis rinci, ada yang hanya menulis "internet mati". Petugas kemudian menentukan prioritas dan meneruskannya ke teknisi.

Masalah utama muncul pada tahap penentuan prioritas. Bila petugas tidak sempat membaca semua tiket secara cermat pada jam sibuk, tiket genting bisa terlambat diteruskan. Sebaliknya, bila semua tiket diperlakukan mendesak, teknisi kehilangan kemampuan membedakan mana yang benar-benar perlu didahulukan. Tabel 3.1 membandingkan kondisi saat ini dengan kondisi yang diusulkan.

Tabel 3.1 Perbandingan proses pemilahan tiket: kondisi saat ini dan usulan

Aspek	Kondisi manual	Dengan bantuan model
Penentuan prioritas	Subjektif, bergantung pada petugas	Konsisten berdasarkan pola data historis
Kecepatan	Bertambah lambat saat tiket menumpuk	Hitungan milidetik per tiket
Tiket ambigu	Tidak ditandai secara khusus	Ditandai lewat nilai kepercayaan rendah
Peran petugas	Memilah semua tiket	Meninjau tiket ambigu dan kasus keamanan
Perbaikan berkelanjutan	Bergantung pada pelatihan staf	Model dilatih ulang dari koreksi petugas

3.3 Alasan Pemilihan Bidang Machine Learning

Alasan pemilihan ML dirumuskan dari karakter masalahnya. Pertama, tersedia (atau dapat dikumpulkan) data historis berlabel berupa tiket lama beserta prioritas yang pernah diberikan petugas. Kedua, aturan pemilihan sulit ditulis lengkap karena bahasa pengguna sangat beragam. Ketiga, keputusan yang dibutuhkan bersifat prediksi kelas, bukan pencarian rute atau kendali perangkat fisik. Keempat, sistem perlu dapat dilatih ulang seiring munculnya jenis masalah baru. Tabel 3.2 membandingkan ML dengan beberapa bidang AI lain yang sempat dipertimbangkan.

Tabel 3.2 Pertimbangan pemilihan bidang AI untuk studi kasus prioritas tiket

Alternatif	Kelebihan	Kekurangan untuk kasus ini
Sistem pakar / aturan	Transparan, tanpa data latih	Aturan sulit mencakup variasi bahasa dan mahal dirawat
Logika fuzzy	Baik untuk nilai kontinu (mis. suhu)	Masukan tiket berupa teks, bukan besaran numerik
Deep learning / model bahasa besar	Pemahaman semantik lebih kaya	Butuh data dan sumber daya besar; risiko privasi jika memakai layanan eksternal
Sistem rekomendasi	Cocok untuk personalisasi	Tujuan bukan menyarankan item ke pengguna
Machine learning (Naive Bayes)	Ringan, cepat, dapat dijelaskan, cocok data kecil	Asumsi kata saling bebas; tidak memahami konteks mendalam

3.4 Data dan Masukan yang Diperlukan

Prinsip yang dipegang dalam merancang masukan adalah minimisasi data: hanya bidang yang benar-benar dibutuhkan model yang dipakai. Untuk keperluan klasifikasi, model hanya membutuhkan teks deskripsi keluhan. Bidang lain yang lazim ada pada tiket dicatat untuk keperluan operasional tetapi tidak dimasukkan sebagai fitur model.

Tabel 3.3 Bidang data tiket dan perannya dalam sistem

Bidang	Contoh isi	Dipakai model?
id_tiket	TKT-001	Tidak (pengenal saja)
deskripsi	"server SIAKAD down, seluruh mahasiswa tidak bisa akses"	Ya (fitur utama)
prioritas	Rendah / Sedang / Tinggi	Ya (label target)

Bidang	Contoh isi	Dipakai model?
nama & kontak pelapor	(tidak dikumpulkan pada praktikum)	Tidak, sengaja dikecualikan
waktu, unit, kategori	Opsional untuk pengembangan lanjut	Tidak pada versi ini

Karena data institusi asli tidak tersedia dan mengandung data pribadi, praktikum ini memakai 200 tiket simulasi. Tiket disusun dari sejumlah pola kalimat keluhan yang divariasikan dengan nama lokasi dan nama sistem, lalu ditambah 20 tiket ambigu yang ditulis tangan untuk menguji kemampuan model pada kasus yang sulit. Keterbatasan pendekatan ini dibahas terbuka pada Bab IV dan Bab V.

3.5 Definisi Kelas Prioritas

Sebelum data dilabeli, kriteria tiap kelas didefinisikan agar pelabelan konsisten. Definisi ini menerjemahkan matriks dampak-urgensi pada Tabel 2.3 ke dalam contoh yang konkret.


Tabel 3.4 Definisi dan kriteria kelas prioritas

Kelas	Kriteria	Contoh tiket	Target respons (usulan)
Tinggi	Layanan inti terhenti atau dampak luas; ada indikasi keamanan atau kehilangan data	Server SIAKAD down; akun diretas; ransomware	≤ 30 menit
Sedang	Mengganggu pekerjaan satu pengguna/keompok kecil, ada solusi sementara	Printer rusak; wifi lambat di satu ruangan	≤ 4 jam
Rendah	Permintaan layanan, pertanyaan, atau perubahan tidak mendesak	Reset kata sandi; instalasi aplikasi; permintaan panduan	≤ 2 hari kerja

Target respons pada tabel adalah usulan penulis untuk keperluan ilustrasi. Nilai sebenarnya ditetapkan oleh masing-masing institusi dalam perjanjian tingkat layanan (*service level agreement*).

3.6 Arsitektur dan Alur Kerja Solusi

Solusi dirancang sebagai *pipeline* berurutan. Teks tiket yang masuk dibersihkan, dipecah menjadi token, dibuang *stopword*-nya, lalu diubah menjadi vektor TF-IDF. Vektor tersebut diproses oleh model *Multinomial Naive Bayes* yang dilatih sebelumnya, dan keluarannya berupa kelas prioritas beserta probabilitasnya. Gambar 3.1 memperlihatkan alurnya.




Gambar 3.1 Alur pipeline klasifikasi prioritas tiket

Pelatihan dan penggunaan berjalan pada jalur yang sama untuk tahap pra-pemrosesan dan vektorisasi. Hal ini penting: bila tahap tersebut diperlakukan berbeda saat pelatihan dan saat prediksi, kinerja model akan menurun tanpa terlihat jelas penyebabnya. Karena itu seluruh tahap dikemas dalam satu objek *Pipeline* scikit-learn.

3.7 Alur Keputusan dengan Keterlibatan Petugas

Model tidak dirancang untuk memutuskan sendiri tanpa pengawasan. Setiap prediksi disertai nilai kepercayaan, yaitu probabilitas tertinggi dari model. Bila nilai kepercayaan berada di bawah ambang 0,70, atau tiket memuat kata kunci yang berkaitan dengan keamanan (misalnya *peretasan*, *phishing*, *ransomware*, atau *bocor*), tiket ditandai untuk ditinjau petugas. Tiket lainnya masuk antrean teknisi dengan prioritas hasil prediksi. Koreksi yang dilakukan petugas disimpan sebagai data latih baru. Gambar 3.2 menggambarkan alur tersebut.



Gambar 3.2 Alur keputusan sistem dengan peninjauan manusia

Ambang 0,70 bukan angka sakral. Nilai ini dipilih karena pada eksperimen Bab IV ia menyaring tiket yang salah diprediksi tanpa terlalu banyak mengurangi cakupan otomatisasi. Institusi yang menerapkannya perlu menyetel ambang tersebut sesuai toleransi risikonya. Aturan kata kunci keamanan ditambahkan setelah penulis menemukan kasus kesalahan yang meyakinkan tetapi berbahaya pada tahap uji demonstrasi.

3.8 Lingkungan Pengembangan

Tabel 3.5 Lingkungan dan pustaka yang digunakan

Komponen	Keterangan
Platform	Google Colab (notebook Python)
Bahasa	Python 3
Pustaka data	pandas, NumPy
Pustaka ML	scikit-learn (TfidfVectorizer, MultinomialNB, Pipeline, metrik evaluasi)
Visualisasi	Matplotlib
Kontrol versi	Git dan GitHub (tautan pada halaman sampul dan Lampiran E)


3.9 Rancangan Evaluasi

Evaluasi dilakukan dalam beberapa lapis. Lapis pertama adalah pembagian *hold-out* 80:20 dengan stratifikasi sehingga proporsi kelas pada data latih dan data uji tetap sama. Lapis kedua adalah validasi silang 5 lipatan pada seluruh data untuk melihat kestabilan. Lapis ketiga adalah eksperimen pembandingan: pengaruh nilai α , pengaruh *n*-gram, dan perbandingan dengan *Logistic Regression* serta *Linear SVM*. Lapis keempat adalah analisis kesalahan dan uji ambang kepercayaan. Semua eksperimen memakai *random seed* tetap (42) supaya hasilnya dapat diulang oleh pembaca.

BAB IV IMPLEMENTASI, HASIL, DAN PEMBAHASAN

4.1 Dataset Tiket

Dataset berisi 200 tiket simulasi berbahasa Indonesia dengan tiga kelas prioritas. Distribusinya hampir seimbang: 70 tiket Sedang, 66 tiket Tinggi, dan 64 tiket Rendah, seperti terlihat pada Gambar 4.1. Keseimbangan ini disengaja agar metrik tidak dibelokkan oleh kelas mayoritas. Pada data helpdesk nyata, tiket berprioritas rendah biasanya jauh lebih banyak, sehingga penanganan ketidakseimbangan kelas akan menjadi pekerjaan tambahan saat data sebenarnya dipakai.



Gambar 4.1 Distribusi kelas prioritas pada dataset

Cuplikan data ditampilkan pada Tabel 4.1. Setiap tiket terdiri atas pengenal, teks deskripsi, dan label prioritas. Seluruh dataset tersedia pada berkas `dataset_tiket_ti.csv` di repositori GitHub.

Tabel 4.1 Cuplikan sembilan tiket dari dataset

ID	Deskripsi tiket	Prioritas
TKT-002	selamat siang, akun admin presensi online diduga diretas, ada login mencurigakan dari luar negeri	Tinggi
TKT-003	server portal penerimaan mahasiswa baru down total, seluruh pengguna tidak bisa mengakses sama sekali	Tinggi
TKT-005	mohon bantuan, database sistem keuangan kampus korup, backup terakhir belum dicoba dipulihkan, layanan lumpuh	Tinggi
TKT-004	website kampus agak lambat dibuka, mungkin karena banyak pengunjung	Sedang
TKT-009	scanner di perpustakaan pusat tidak terdeteksi oleh komputer, dokumen perlu dipindai hari ini	Sedang
TKT-012	aplikasi presensi online lambat di akun saya, halaman lama sekali terbuka	Sedang

ID	Deskripsi tiket	Prioritas
TKT-001	minta panduan penggunaan sistem KRS online untuk mahasiswa semester awal	Rendah
TKT-010	selamat siang, minta panduan penggunaan sistem ujian daring untuk mahasiswa semester awal	Rendah
TKT-014	tanya prosedur peminjaman kabel HDMI untuk kegiatan di gedung rektorat	Rendah

Perlu ditegaskan bahwa dataset ini dibangkitkan dari sejumlah pola kalimat. Akibatnya, sebagian besar tiket memiliki struktur yang mirip dan mudah dipisahkan. Hal ini tentu membuat hasil evaluasi lebih optimistis daripada yang akan didapat pada data nyata. Untuk mengurangi kesan terlalu mudah, penulis menambahkan 20 tiket ambigu, misalnya "wifi mati di ruang saya, tidak bisa koneksi sama sekali" yang memuat kata bernada berat tetapi sebenarnya hanya menyangkut satu pengguna. Bagian pembahasan (4.13) kembali ke isu ini.

4.2 Pra-pemrosesan Teks

Pra-pemrosesan diimplementasikan dalam dua fungsi. Fungsi `bersihkan()` mengubah teks menjadi huruf kecil, mengganti karakter selain huruf dan angka dengan spasi, lalu merapikan spasi berlebih. Fungsi `tok()` memecah hasilnya menjadi token dan membuang daftar *stopword* sederhana yang disusun penulis sesuai konteks tiket.

Kode 4.1 Fungsi pra-pemrosesan

```
def bersihkan(t):
    t = t.lower()
    t = re.sub(r"^[a-z0-9\s]", " ", t)
    return re.sub(r"\s+", " ", t).strip()

STOP = {"di", "yang", "dan", "ke", "dari", "untuk", "saya", "mohon", "tolong",
        "ada", "ini", "itu", "dengan", "pada", "sudah", "atau", "agar",
        "halo", "selamat", "siang", "tim", "ti", "bantuan"}

def tok(t):
    return [w for w in bersihkan(t).split() if w not in STOP]
```

Sebagai ilustrasi, kalimat "Halo tim TI, server SIAKAD down total, seluruh pengguna tidak bisa mengakses sama sekali!" menjadi deretan token: server, siakad, down, total, seluruh, pengguna, tidak, bisa, mengakses, sama, sekali. Kata *tidak* dan *bisa* sengaja tidak dimasukkan ke daftar *stopword* karena kombinasi keduanya membawa makna gangguan.

4.3 Pembagian Data dan Pelatihan Model

Data dibagi secara berstrata menjadi 160 tiket latih (80%) dan 40 tiket uji (20%). Model disusun sebagai *Pipeline* yang menggabungkan *TfidfVectorizer* dan *MultinomialNB*. Vektorisasi memakai unigram dan bigram serta *sublinear tf*, dan nilai α ditetapkan 0,1 berdasarkan eksperimen pada subbab 4.6.

Kode 4.2 Pembagian data, pembentukan pipeline, dan pelatihan

```
X_tr, X_te, y_tr, y_te = train_test_split(
    df["bersih"], df["prioritas"], test_size=0.2,
    stratify=df["prioritas"], random_state=42)

model = Pipeline([
    ("tfidf", TfidfVectorizer(tokenizer=tok, token_pattern=None,
                             ngram_range=(1, 2), sublinear_tf=True)),
    ("clf", MultinomialNB(alpha=0.1)),
]).fit(X_tr, y_tr)

pred = model.predict(X_te)
print(classification_report(y_te, pred, digits=3))
```

4.4 Hasil Evaluasi pada Data Uji

Pada 40 tiket uji, model mencapai akurasi 97,5%, yaitu 39 dari 40 tiket diprediksi benar. Rincian per kelas ditunjukkan pada Tabel 4.2 dan *confusion matrix* pada Gambar 4.2.

Tabel 4.2 Metrik per kelas pada data uji (n = 40)

Kelas	Presisi	Recall	F1-score	Jumlah tiket uji
Rendah	1,000	1,000	1,000	13
Sedang	1,000	0,929	0,963	14
Tinggi	0,929	1,000	0,963	13
Rerata makro	0,976	0,976	0,975	40

Label sebenarnya	Rendah	13	0	0
	Sedang	0	13	1
	Tinggi	0	0	13
		Rendah	Sedang	Tinggi
		Prediksi		

Gambar 4.2 Confusion matrix pada data uji

Kelas Rendah terklasifikasi sempurna. Satu-satunya kesalahan terjadi pada tiket berlabel Sedang yang diprediksi Tinggi, sehingga presisi kelas Tinggi turun menjadi 0,929 dan recall kelas Sedang menjadi 0,929. Dari sudut pandang risiko, jenis kesalahan ini tergolong *over-triage*, yaitu tiket dinaikkan prioritasnya. Ini lebih dapat diterima daripada sebaliknya, meski tetap memakan waktu teknisi. Tidak ada tiket Tinggi yang lolos menjadi prioritas lebih rendah pada data uji ini.

Angka ini baru berasal dari 40 tiket, sehingga satu tiket saja mengubah akurasi sebesar 2,5 poin. Karena itu penulis tidak berhenti di sini dan melanjutkannya dengan validasi silang.

4.5 Validasi Silang 5 Lipatan


Tabel 4.3 Akurasi tiap lipatan pada validasi silang berlapis

Lipatan	1	2	3	4	5	Rerata $\pm$ SD
Akurasi	97,5%	90,0%	97,5%	92,5%	90,0%	93,5% $\pm$ 3,8%

Rerata akurasi validasi silang adalah 93,5% dengan simpangan baku sekitar 3,4 poin. Angkanya lebih rendah daripada 97,5% pada pembagian tunggal, dan itu wajar: hasil hold-out sebelumnya kebetulan berada di sisi yang menguntungkan. Untuk melaporkan kinerja model, angka 93,5% dengan rentang yang jelas lebih layak dipercaya daripada satu angka 97,5%.

4.6 Pengaruh Parameter Penghalusan (α)

Nilai α diuji pada enam tingkat dengan validasi silang yang sama. Hasilnya tampak pada Gambar 4.3 dan Tabel 4.4.



Gambar 4.3 Akurasi rata-rata validasi silang terhadap nilai α

Tabel 4.4 Akurasi validasi silang untuk berbagai nilai α

α	Akurasi rerata	Simpangan baku
0,01	93,0%	2,9%
0,05	93,5%	3,4%
0,1	93,5%	3,4%
0,5	93,0%	2,9%
1,0	93,0%	2,9%
2,0	93,5%	3,4%

Perbedaan antarnilai α sangat kecil, hanya berkisar 0,5 poin, dan berada jauh di dalam rentang simpangan baku. Dengan kata lain, pada dataset ini model tidak sensitif terhadap α . Penulis tetap memilih 0,1 karena berada pada kelompok akurasi tertinggi, tetapi tidak menganggap pemilihan tersebut sebagai temuan yang kuat.

4.7 Pengaruh Rentang N-gram

Tabel 4.5 Perbandingan rentang n-gram (Naive Bayes, $\alpha = 0,1$)

Konfigurasi fitur	Akurasi rerata	Simpangan baku
Unigram (1,1)	93,0%	2,9%
Unigram+Bigram (1,2)	93,5%	3,4%
Hingga trigram (1,3)	93,5%	3,4%

Penambahan bigram hanya menaikkan akurasi sekitar 0,5 poin, dan trigram tidak memberi tambahan. Untuk teks pendek seperti tiket, unigram sudah menangkap sebagian besar informasi. Bigram tetap dipertahankan karena frasa seperti "tidak bisa" dan "sejak pagi" secara intuitif informatif, dengan kesadaran bahwa keuntungannya kecil pada data ini.

4.8 Perbandingan dengan Algoritme Lain

Tabel 4.6 Perbandingan tiga algoritme dengan fitur TF-IDF yang sama

Algoritme	Akurasi CV (rerata $\pm$ SD)	Akurasi uji	F1 makro uji
Multinomial Naive Bayes	93,5% $\pm$ 3,4%	97,5%	0,975
Logistic Regression	93,5% $\pm$ 3,0%	100,0%	1,000
Linear SVM	94,0% $\pm$ 2,5%	100,0%	1,000

Ketiga algoritme berada pada kisaran akurasi validasi silang yang nyaris sama (93,5% sampai 94,0%). *Logistic Regression* dan *Linear SVM* memperoleh akurasi 100% pada pembagian uji tunggal, sedangkan Naive Bayes 97,5%. Namun, perbedaan itu hanya satu tiket dan tidak tampak pada validasi silang, sehingga tidak cukup kuat untuk menyatakan bahwa satu algoritme lebih baik. Kesimpulan yang lebih jujur adalah bahwa pada data sekecil dan sepola ini, pilihan algoritme tidak menentukan hasil. Naive Bayes tetap dipilih karena paling sederhana untuk dijelaskan dan probabilitasnya langsung tersedia untuk mekanisme ambang kepercayaan.

4.9 Fitur yang Paling Berpengaruh

Salah satu keunggulan Naive Bayes adalah kita dapat melihat kata mana yang paling menarik prediksi ke suatu kelas. Gambar 4.4 menampilkan delapan fitur teratas untuk masing-masing kelas, diurutkan berdasarkan selisih log-peluangnya terhadap kelas lain.



Gambar 4.4 Fitur (kata/bigram) paling khas untuk tiap kelas

Untuk kelas Tinggi, fitur teratasnya adalah "seluruh", "semua", "layanan", "sejak pagi", yang sesuai dengan dugaan awal bahwa kata bernuansa cakupan luas menandai gangguan besar. Untuk kelas Rendah muncul "minta", "panduan penggunaan", "minta panduan", khas permintaan layanan. Namun, ada juga fitur

yang mencurigakan, seperti "semester awal" pada kelas Rendah atau "sejak pagi" pada kelas Tinggi. Fitur-fitur itu bukan penanda tingkat keparahan yang sesungguhnya; mereka muncul karena kebetulan terikat pada pola kalimat tertentu di dataset simulasi. Gejala ini dikenal sebagai *shortcut learning*, yaitu model memakai jalan pintas yang benar pada data latih tetapi tidak berlaku umum. Temuan ini menjadi alasan kuat mengapa hasil praktikum tidak boleh langsung diekstrapolasi ke data nyata.

4.10 Analisis Kesalahan

Pada data uji terdapat satu kesalahan: tiket "wifi mati di ruang saya tidak bisa koneksi sama sekali" berlabel Sedang, tetapi diprediksi Tinggi dengan tingkat kepercayaan hanya 0,56. Tiket ini sengaja dibuat ambigu. Kata "mati" dan "tidak bisa koneksi sama sekali" mirip dengan gangguan besar, padahal frasa "di ruang saya" menunjukkan dampaknya hanya satu pengguna. Model berbasis kantong kata tidak mampu memahami bahwa lingkup dampak dinyatakan oleh frasa lokatif tersebut.

Yang menarik, rerata kepercayaan pada prediksi yang benar adalah 0,99, sementara pada prediksi yang salah hanya 0,56. Artinya, nilai kepercayaan memberi sinyal berguna untuk memilah tiket yang perlu ditinjau manusia. Inilah dasar mekanisme ambang pada Bab III.

4.11 Pengaruh Ambang Kepercayaan

Tabel 4.7 Cakupan otomatisasi dan akurasi pada berbagai ambang kepercayaan (data uji)

Ambang	Tiket diproses otomatis	Akurasi tiket otomatis
0,00	100,0%	97,5%
0,50	100,0%	97,5%
0,60	97,5%	100,0%
0,70	97,5%	100,0%
0,80	95,0%	100,0%

Pada ambang 0,60 dan 0,70, model memproses 97,5% tiket uji secara otomatis dengan akurasi 100% pada tiket tersebut, sedangkan satu tiket ambigu diserahkan kepada petugas. Meningkatkan ambang menjadi 0,80 menurunkan cakupan menjadi 95% tanpa menambah akurasi. Karena itu 0,70 dipilih sebagai titik kompromi. Dengan hanya 40 tiket uji, angka ini sebaiknya dibaca sebagai gambaran arah, bukan patokan yang pasti.

4.12 Demonstrasi Prediksi pada Tiket Baru

Untuk demonstrasi, enam tiket baru yang tidak ada pada dataset dimasukkan ke fungsi keputusan yang menggabungkan model, ambang kepercayaan, dan kata kunci keamanan. Hasilnya tercantum pada Tabel 4.8.

Kode 4.3 Fungsi keputusan dengan ambang kepercayaan dan kata kunci keamanan

```
KUNCI = ["peretasan", "diretas", "phishing", "ransomware", "bocor",  
         "serangan", "malware", "mencurigakan"]  
  
def putuskan(teks, ambang=0.70):  
    p = model.predict_proba([bersihkan(teks)])[0]  
    kelas, conf = nb.classes_[p.argmax()], float(p.max())  
    if conf < ambang or any(k in teks.lower() for k in KUNCI):  
        return kelas, conf, "TINJAU PETUGAS"  
    return kelas, conf, "OTOMATIS"
```

Tabel 4.8 Hasil prediksi pada enam tiket baru

Tiket baru	Prediksi	Kepercayaan	Tindakan
server SIAKAD tidak bisa diakses semua mahasiswa saat pengisian KRS	Tinggi	0,99	Otomatis
printer di ruang dosen macet kertasnya	Sedang	0,92	Otomatis
mohon bantuan reset password email kampus	Rendah	0,91	Otomatis
wifi lantai 3 putus dan ada indikasi serangan siber	Sedang	0,93	Tinjau petugas
minta panduan penggunaan e-learning untuk mahasiswa baru	Rendah	0,98	Otomatis
laptop saya lambat sekali	Sedang	0,95	Otomatis

Lima dari enam tiket menghasilkan prediksi yang sesuai harapan penulis. Kasus keempat, "wifi lantai 3 putus dan ada indikasi serangan siber", adalah contoh yang paling instruktif. Model memprediksi Sedang dengan kepercayaan tinggi (0,93) padahal tiket tersebut seharusnya bernilai Tinggi karena menyangkut dugaan serangan. Model gagal karena kata "serangan" tidak ada pada data latih, sedangkan frasa "wifi putus" identik dengan gangguan lokal. Aturan kata kunci keamanan menyelamatkan kasus ini dengan mengalihkannya ke petugas. Tanpa aturan tersebut, prediksi salah tetapi meyakinkan itu akan lolos otomatis.

Pada dataset sendiri, aturan kata kunci menandai 16 dari 200 tiket, seluruhnya berlabel Tinggi. Konsekuensinya, sebagian tiket keamanan yang sebenarnya sudah diprediksi benar tetap harus ditinjau manusia. Penulis menilai ini pertukaran yang

wajar: sedikit beban tinjauan tambahan diterima demi keamanan pada kategori yang risikonya paling besar.

4.13 Pembahasan

Secara keseluruhan, model *Multinomial Naive Bayes* dengan TF-IDF mampu memisahkan tiket ke tiga prioritas dengan akurasi sekitar 93,5% pada validasi silang dan 97,5% pada data uji. Angka tersebut menunjukkan bahwa pola bahasa tiket memang mengandung informasi yang cukup untuk menebak prioritas. Namun, angka tersebut perlu dibaca dengan tiga catatan.

Catatan pertama menyangkut data. Dataset yang dibangkitkan dari pola kalimat cenderung lebih mudah dipisahkan dan memiliki kosakata terbatas. Fakta bahwa tiga algoritme yang berbeda memberi hasil hampir identik mengindikasikan bahwa masalahnya sendiri belum sesulit kasus nyata. Pada data institusi sebenarnya, tiket lebih pendek, penuh singkatan, bercampur bahasa Indonesia, Inggris, dan bahasa daerah, serta sering salah ketik. Kinerja hampir pasti lebih rendah dan perlu diukur ulang.

Catatan kedua menyangkut jenis kesalahan. Kesalahan terbesar bukan pada tiket yang jelas, melainkan pada tiket yang maknanya bergantung pada konteks, seperti lingkup dampak atau dugaan keamanan. Di sinilah desain sistem yang melibatkan manusia dan aturan pelengkap menjadi lebih menentukan daripada memilih algoritme yang lebih canggih.

Catatan ketiga menyangkut kejujuran metodologis. Perbedaan kecil antarkonfigurasi, seperti nilai α atau pilihan algoritme, berada dalam rentang derau statistik pada data sekecil ini. Penulis sengaja tidak mengklaim satu konfigurasi sebagai yang terbaik. Yang dapat diklaim secara wajar adalah bahwa pendekatan ini layak sebagai *baseline* dan sebagai titik awal uji coba dengan data nyata.

BAB V MANFAAT, KETERBATASAN, DAN RISIKO ETIKA/PRIVASI

5.1 Manfaat

Manfaat operasional

Manfaat paling langsung adalah percepatan pemilahan. Model memproses satu tiket dalam hitungan milidetik, sehingga petugas tidak perlu lagi membaca dan menilai semua tiket dari awal. Waktu mereka dapat dialihkan untuk tiket yang ambigu, kasus keamanan, dan komunikasi dengan pengguna. Konsistensi juga meningkat: dua tiket dengan isi yang mirip akan mendapat perlakuan yang sama, tidak bergantung pada siapa yang bertugas atau seberapa lelah petugas tersebut.

Manfaat manajerial

Dari sisi pengelola, prioritas yang terstandar memudahkan pemantauan target respons dan pelaporan layanan. Nilai kepercayaan model juga menjadi indikator baru: proporsi tiket yang perlu ditinjau dapat dipantau dari waktu ke waktu sebagai tanda apakah jenis keluhan pengguna mulai berubah. Data koreksi dari petugas menjadi aset untuk memperbaiki model secara berkala.

Manfaat bagi pengguna

Pengguna diuntungkan secara tidak langsung karena gangguan yang berdampak luas lebih cepat sampai ke teknisi. Namun, manfaat ini hanya nyata bila sistem berjalan andal dan tidak disalahgunakan. Pengguna juga perlu diberi tahu bahwa prioritas tiketnya ditentukan dengan bantuan sistem otomatis, dan tetap dapat meminta peninjauan ulang oleh petugas.

5.2 Keterbatasan

Tabel 5.1 Keterbatasan solusi dan dampaknya

Keterbatasan	Penjelasan	Dampak
Data simulasi	Dataset dibangkitkan dari pola kalimat, bukan tiket nyata	Kinerja pada data nyata kemungkinan lebih rendah
Jumlah data kecil	200 tiket; data uji hanya 40	Angka metrik tidak stabil; selisih kecil tidak bermakna
Asumsi independensi kata	Urutan dan konteks kalimat diabaikan	Gagal pada frasa yang bergantung konteks (mis. lingkup dampak)
Kosakata terbatas	Kata baru di luar data latih diabaikan	Prediksi meyakinkan tetapi keliru (kasus "serangan siber")

Keterbatasan	Penjelasan	Dampak
Shortcut learning	Model dapat memakai pola kalimat kebetulan	Tidak berlaku umum pada data baru
Hanya teks	Tidak memakai waktu, unit, atau riwayat pelapor	Kehilangan petunjuk berguna, mis. jam ujian
Bahasa	Hanya bahasa Indonesia baku dan semi-baku	Singkatan, bahasa campur, dan salah ketik belum teruji
Label bersifat subjektif	Label awal berasal dari penilaian manusia	Model mewarisi ketidakkonsistenan pelabel

5.3 Risiko Etika dan Privasi

Privasi dan perlindungan data pribadi

Teks tiket dapat memuat nama, NIM, nomor telepon, alamat surel, atau kata sandi yang ditempelkan pengguna. Bila tiket-tiket ini dipakai sebagai data latih tanpa disaring, data pribadi tersebut berpindah dari sistem tiket ke lingkungan pengembangan model. Hal ini berpotensi bertentangan dengan prinsip pembatasan tujuan dan minimisasi data pada UU Pelindungan Data Pribadi. Praktikum ini menghindarinya dengan tidak memakai data nyata sama sekali dan hanya mengambil kolom deskripsi.

Bias dan keadilan

Jika data historis dilabeli oleh petugas yang cenderung memprioritaskan keluhan dari kelompok tertentu, misalnya pimpinan atau fakultas tertentu, model akan mempelajari kebiasaan itu sebagai kebenaran. Selain itu, pengguna yang menulis dengan bahasa sederhana atau tidak baku dapat menghasilkan prediksi yang lebih sering keliru dibandingkan pengguna yang menulis rapi. Dampaknya, keluhan yang sama bisa diprioritaskan berbeda hanya karena gaya penulisan.

Transparansi dan akuntabilitas

Pengguna dan petugas berhak mengetahui bahwa ada sistem otomatis yang ikut menentukan prioritas, dan alasan di balik keputusannya. Naive Bayes membantu karena kata pemicu dapat ditampilkan sebagai penjelasan. Meski begitu, tanggung jawab akhir tetap pada manusia dan institusi, bukan pada model. Perlu ada jalur banding: pengguna atau petugas dapat mengubah prioritas, dan perubahan itu tercatat.

Otomatisasi berlebih dan keamanan

Bahaya lain adalah ketergantungan berlebih: petugas terbiasa mempercayai hasil model dan berhenti memeriksa. Kasus "serangan siber" pada Bab IV memperlihatkan bahwa model dapat salah dengan keyakinan tinggi. Dari sisi keamanan, model dan data latih juga menjadi target: pihak yang mengetahui pola kata pemicu bisa sengaja menulis tiket dengan kata tertentu agar tiket palsunya diprioritaskan, atau sebaliknya menekan prioritas tiket tertentu.

Tabel 5.2 Risiko dan langkah mitigasi

Risiko	Langkah mitigasi
Kebocoran data pribadi pada data latih	Hapus atau samarkan nama, NIM, kontak, dan kata sandi sebelum data dipakai; batasi akses data latih
Bias pelabelan	Tetapkan panduan pelabelan tertulis; audit sampel label oleh lebih dari satu petugas
Perlakuan tidak adil antar gaya bahasa	Ukur kinerja per kelompok pengguna; perluas data dengan ragam bahasa
Prediksi keliru yang meyakinkan	Ambang kepercayaan, aturan kata kunci keamanan, dan peninjauan manusia
Ketergantungan berlebih	Audit acak berkala terhadap tiket otomatis; pelatihan petugas
Manipulasi tiket	Pantau lonjakan kata pemicu; batasi pelaporan massal; peninjauan pola tidak wajar
Kurangnya transparansi	Tampilkan kata pemicu dan status "dibantu sistem otomatis"; sediakan jalur banding

5.4 Rekomendasi Tata Kelola

- Menetapkan pemilik sistem (*system owner*) yang bertanggung jawab atas kinerja dan keputusan otomatis.
- Menyusun kebijakan data: apa yang boleh dipakai untuk pelatihan, berapa lama disimpan, dan siapa yang boleh mengakses.
- Memantau metrik secara berkala, termasuk proporsi tiket yang ditinjau dan tingkat koreksi petugas.
- Melakukan evaluasi ulang dan pelatihan ulang model pada jadwal tetap, misalnya tiap semester atau setelah perubahan besar sistem.
- Menyediakan dokumentasi singkat yang menjelaskan cara kerja, batas, dan risiko sistem untuk petugas dan pengguna.

5.5 Rencana Penerapan Bertahap

Bila hasil praktikum ini dilanjutkan ke penerapan sungguhan, penulis menyarankan tiga tahap. Tahap pertama adalah *shadow mode*: model berjalan di belakang layar dan hanya dibandingkan dengan keputusan petugas tanpa memengaruhi antrean. Tahap kedua adalah mode saran: prediksi ditampilkan kepada petugas sebagai rekomendasi yang dapat diterima atau diubah. Tahap ketiga adalah otomatisasi terbatas: hanya tiket dengan kepercayaan tinggi dan bukan kategori keamanan yang diproses otomatis, dengan audit rutin. Setiap perpindahan tahap didasarkan pada data kinerja, bukan jadwal semata.

BAB VI KESIMPULAN DAN SARAN

6.1 Kesimpulan

1. Studi kasus klasifikasi prioritas tiket layanan TI sesuai dengan karakter *machine learning* terawasi: tersedia data berlabel, aturan pemilahan sulit ditulis manual, dan keluaran yang dibutuhkan berupa kelas. Rancangan solusi berupa *pipeline* pembersihan teks, TF-IDF, dan *Multinomial Naive Bayes*, dilengkapi ambang kepercayaan dan peninjauan manusia.
2. Pada 200 tiket simulasi, model mencapai akurasi 97,5% pada data uji (39 dari 40 tiket) dan rerata 93,5% pada validasi silang 5 lipatan. *Logistic Regression* dan *Linear SVM* memberi hasil validasi silang yang hampir sama (93,5% dan 94,0%), sehingga pada data ini pilihan algoritme tidak menentukan.
3. Kesalahan model terkonsentrasi pada tiket yang maknanya bergantung pada konteks, seperti lingkup dampak dan dugaan keamanan. Nilai kepercayaan terbukti membantu menyaring tiket ambigu, dan aturan kata kunci keamanan perlu ditambahkan karena model dapat salah dengan keyakinan tinggi.
4. Manfaat sistem berupa percepatan dan konsistensi pemilahan hanya akan nyata bila risiko diantisipasi: perlindungan data pribadi, bias pelabelan dan gaya bahasa, ketergantungan berlebih, serta manipulasi tiket. Otomatisasi sebaiknya diposisikan sebagai alat bantu, bukan pengganti keputusan petugas.

6.2 Saran

- Menguji model pada tiket nyata yang telah dianonimkan, dengan izin institusi, dan menambah ragam data (singkatan, bahasa campur, salah ketik) serta menangani ketidakseimbangan kelas.
- Menambahkan fitur non-teks seperti waktu, unit pelapor, dan kategori masalah, serta mengevaluasi pemakaian model bahasa berbasis *transformer* yang dijalankan di lingkungan institusi sendiri bila sumber daya tersedia.
- Mengevaluasi kinerja per kelompok pengguna untuk mendeteksi bias, lalu mengintegrasikan model ke aplikasi tiket dengan pencatatan koreksi petugas.

DAFTAR PUSTAKA

- AXELOS. (2019). *ITIL Foundation: ITIL 4 Edition*. TSO (The Stationery Office).
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- Pedregosa, F., Varoquaux, G., Gramfort, A., dkk. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Republik Indonesia. (2022). *Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi*.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (edisi ke-4). Pearson.

Catatan: keenam sumber tersebut adalah buku dan dokumen yang umum dirujuk di bidangnya. Sebelum dikumpulkan, mahasiswa disarankan memeriksa kembali edisi, halaman, dan penulisan sesuai pedoman sitasi (APA/IEEE) yang ditetapkan program studi.

LAMPIRAN A KODE PROGRAM LENGKAP

Berikut kode lengkap yang dijalankan pada Google Colab. Berkas yang sama tersedia pada repositori GitHub (klasifikasi_tiket.py dan notebook .ipynb) dan menghasilkan seluruh angka pada Bab IV.

```
"""Klasifikasi prioritas tiket IT Helpdesk (Rendah/Sedang/Tinggi).
Algoritme: TF-IDF + Multinomial Naive Bayes. Jalankan di Google Colab.
Prasyarat: unggah dataset_tiket_ti.csv ke sesi Colab.
"""

import re
import pandas as pd
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.model_selection import (train_test_split, StratifiedKFold,
                                     cross_val_score)
from sklearn.naive_bayes import MultinomialNB
from sklearn.linear_model import LogisticRegression
from sklearn.svm import LinearSVC
from sklearn.pipeline import Pipeline
from sklearn.metrics import (accuracy_score, classification_report,
                             confusion_matrix)

SEED = 42
df = pd.read_csv("dataset_tiket_ti.csv")

# 1. Pra-pemrosesan teks
def bersihkan(t):
    t = t.lower()
    t = re.sub(r"^[a-z0-9\s]", " ", t)
    return re.sub(r"\s+", " ", t).strip()

STOP = {"di", "yang", "dan", "ke", "dari", "untuk", "saya", "mohon",
        "tolong", "ada", "ini", "itu", "dengan", "pada", "sudah",
        "atau", "agar", "halo", "selamat", "siang", "tim", "ti",
        "bantuan"}

def tok(t):
    return [w for w in bersihkan(t).split() if w not in STOP]

df["bersih"] = df["deskripsi"].apply(bersihkan)

# 2. Pembagian data 80:20 berstrata
X_tr, X_te, y_tr, y_te = train_test_split(
    df["bersih"], df["prioritas"], test_size=0.2,
    stratify=df["prioritas"], random_state=SEED)

# 3. Pipeline: TF-IDF (unigram+bigram) -> classifier
def buat_model(clf, ngram=(1, 2)):
    tfidf = TfidfVectorizer(tokenizer=tok, token_pattern=None,
```

```

        ngram_range=ngram, sublinear_tf=True)
    return Pipeline([("tfidf", tfidf), ("clf", clf)])

model = buat_model(MultinomialNB(alpha=0.1)).fit(X_tr, y_tr)
pred = model.predict(X_te)

# 4. Evaluasi hold-out
labels = ["Rendah", "Sedang", "Tinggi"]
print("Akurasi uji:", accuracy_score(y_te, pred))
print(classification_report(y_te, pred, digits=3))
print(confusion_matrix(y_te, pred, labels=labels))

# 5. Validasi silang 5 lipatan
skf = StratifiedKFold(5, shuffle=True, random_state=SEED)
cv = cross_val_score(buat_model(MultinomialNB(alpha=0.1)),
                    df["bersih"], df["prioritas"], cv=skf)
print("CV:", cv.round(3), "rerata", cv.mean().round(3))

# 6. Perbandingan algoritme
for nama, clf in [("Naive Bayes", MultinomialNB(alpha=0.1)),
                  ("Logistic Regression",
                   LogisticRegression(max_iter=1000, C=10)),
                  ("Linear SVM", LinearSVC(C=1.0))]:
    s = cross_val_score(buat_model(clf), df["bersih"],
                      df["prioritas"], cv=skf)
    print(f"{nama}: {s.mean():.3f} +/- {s.std():.3f}")

# 7. Aturan keputusan: ambang kepercayaan + kata kunci keamanan
nb = model.named_steps["clf"]
KUNCI = ["peretasan", "diretas", "phishing", "ransomware", "bocor",
        "serangan", "malware", "mencurigakan"]

def putuskan(teks, ambang=0.70):
    p = model.predict_proba([bersihkan(teks)])[0]
    kelas, conf = nb.classes_[p.argmax()], float(p.max())
    if conf < ambang or any(k in teks.lower() for k in KUNCI):
        return kelas, conf, "TINJAU PETUGAS"
    return kelas, conf, "OTOMATIS"

# 8. Demonstrasi tiket baru
baru = [
    "server SIAKAD tidak bisa diakses semua mahasiswa saat pengisian KRS",
    "printer di ruang dosen macet kertasnya",
    "mohon bantuan reset password email kampus",
    "wifi lantai 3 putus dan ada indikasi serangan siber",
    "minta panduan penggunaan e-learning untuk mahasiswa baru",
    "laptop saya lambat sekali",
]
for t in baru:
    print(t, "->", putuskan(t))

```

LAMPIRAN B CUPLIKAN DATASET TAMBAHAN

Tabel B.1 Empat belas tiket pertama dalam dataset

ID	Deskripsi tiket	Prioritas
TKT-001	minta panduan penggunaan sistem KRS online untuk mahasiswa semester awal	Rendah
TKT-002	selamat siang, akun admin presensi online diduga diretas, ada login mencurigakan dari luar negeri	Tinggi
TKT-003	server portal penerimaan mahasiswa baru down total, seluruh pengguna tidak bisa mengakses sama sekali	Tinggi
TKT-004	website kampus agak lambat dibuka, mungkin karena banyak pengunjung	Sedang
TKT-005	mohon bantuan, database sistem keuangan kampus korup, backup terakhir belum dicoba dipulihkan, layanan lumpuh	Tinggi
TKT-006	halo tim TI, data nilai di SIAKAD hilang setelah pembaruan sistem, mohon ditangani segera	Tinggi
TKT-007	mohon bantuan, server SIAKAD down total, seluruh pengguna tidak bisa mengakses sama sekali	Tinggi
TKT-008	data mahasiswa terlihat oleh akun yang seharusnya tidak punya akses	Tinggi
TKT-009	scanner di perpustakaan pusat tidak terdeteksi oleh komputer, dokumen perlu dipindai hari ini	Sedang
TKT-010	selamat siang, minta panduan penggunaan sistem ujian daring untuk mahasiswa semester awal	Rendah
TKT-011	jaringanantai dua putus, sekitar seratus komputer tidak bisa online	Tinggi
TKT-012	aplikasi presensi online lambat di akun saya, halaman lama sekali terbuka	Sedang
TKT-013	aplikasi portal penerimaan mahasiswa baru lambat di akun saya, halaman lama sekali terbuka	Sedang
TKT-014	tanya prosedur peminjaman kabel HDMI untuk kegiatan di gedung rektorat	Rendah

LAMPIRAN C NASKAH PRESENTASI 5–7 MENIT

Naskah ini disusun sebagai panduan berbicara, bukan untuk dibaca kata per kata. Dengan kecepatan bicara normal, seluruhnya sekitar 6 menit. Isi dapat disesuaikan dengan gaya masing-masing.

Tabel C.1 Rencana presentasi dan alokasi waktu

Slide	Isi	Waktu
1	Judul, nama, bidang AI (Machine Learning)	0:20
2	Masalah: tiket menumpuk, prioritas ditentukan manual dan subjektif	0:45
3	Mengapa ML? Perbandingan singkat dengan sistem pakar, fuzzy, dan deep learning	0:45
4	Data dan masukan: teks deskripsi, label Rendah/Sedang/Tinggi, 200 tiket simulasi	0:40
5	Cara kerja: pipeline (Gambar 3.1) dan contoh hitung Naive Bayes	1:00
6	Demonstrasi Colab: melatih model dan memprediksi tiket baru	1:15
7	Hasil: akurasi 97,5% (uji), 93,5% (CV), confusion matrix, contoh kesalahan	0:45
8	Manfaat, keterbatasan, risiko etika/privasi dan mitigasi	0:45
9	Kesimpulan dan saran; tanya jawab	0:25

Poin bicara utama

- "Masalah yang saya ambil adalah penentuan prioritas tiket helpdesk. Saat tiket menumpuk, tiket genting bisa terlambat ditangani."
- "Saya memilih Machine Learning karena ada data berlabel dan aturannya sulit ditulis lengkap. Saya memakai Naive Bayes karena ringan dan bisa dijelaskan kata per kata."
- "Data yang saya pakai adalah 200 tiket simulasi. Ini keterbatasan yang saya sadari, jadi hasilnya tidak bisa langsung dianggap sama dengan data nyata."
- "Di demonstrasi ini terlihat satu kasus penting: tiket 'serangan siber' diprediksi Sedang dengan keyakinan tinggi. Karena itu saya menambahkan aturan kata kunci keamanan dan peninjauan petugas."
- "Kesimpulannya, sistem ini cocok sebagai alat bantu petugas, bukan pengganti, dan perlu pengawasan terkait privasi dan bias."

Pertanyaan yang mungkin diajukan

- **Mengapa akurasi validasi silang lebih rendah dari akurasi uji?** Karena data uji hanya 40 tiket dan kebetulan lebih mudah; validasi silang menggunakan seluruh data dan lebih stabil.
- **Mengapa bukan deep learning?** Data sedikit, kebutuhan sumber daya lebih besar, dan penjelasan keputusan lebih sulit. Untuk *baseline* Naive Bayes sudah memadai.
- **Apa arti "naif"?** Model menganggap kata-kata saling bebas jika kelasnya diketahui. Asumsi ini disederhanakan tetapi sering cukup baik.
- **Bagaimana jika ada data pribadi di tiket?** Harus dianonimkan sebelum dipakai sebagai data latih, sesuai prinsip minimisasi data pada UU PDP.

LAMPIRAN D DAFTAR PERIKSA KESESUAIAN DENGAN PETUNJUK TUGAS

Tabel D.1 Pemetaan unsur laporan yang diminta terhadap isi laporan

Unsur yang diminta	Lokasi pada laporan
Judul dan bidang AI yang dipilih	Halaman sampul; subbab 3.1
Deskripsi masalah	Subbab 1.1, 1.2, dan 3.2
Alasan pemilihan bidang AI	Subbab 2.1 dan 3.3 (Tabel 2.1 dan 3.2)
Data atau masukan yang diperlukan	Subbab 3.4 (Tabel 3.3) dan 4.1
Gambaran cara kerja solusi	Subbab 3.6 dan 3.7 (Gambar 3.1 dan 3.2); subbab 2.4
Keluaran yang diharapkan	Subbab 3.5 (kelas prioritas), 4.4, dan 4.12
Manfaat, keterbatasan, risiko etika/privasi	Bab V
Demonstrasi sederhana (Google Colab/Python)	Bab IV dan Lampiran A
Presentasi 5–7 menit	Lampiran C
Luaran: laporan PDF, slide, kode/notebook, tautan GitHub	Laporan ini; berkas notebook dan dataset terpisah; Lampiran E

LAMPIRAN E PANDUAN MENJALANKAN DAN TAUTAN REPOSITORI

Tautan repositori GitHub: [https://github.com/\[username-anda\]/klasifikasi-prioritas-tiket-ti](https://github.com/[username-anda]/klasifikasi-prioritas-tiket-ti) (ganti dengan tautan asli setelah repositori dibuat).

Struktur repositori yang disarankan:

- README.md: ringkasan proyek dan cara menjalankan
- dataset_tiket_ti.csv: dataset simulasi 200 tiket
- klasifikasi_tiket.py: skrip lengkap pelatihan dan evaluasi
- klasifikasi_tiket.ipynb: notebook untuk Google Colab
- gambar/: grafik hasil (distribusi, confusion matrix, dsb.)
- laporan/: berkas PDF laporan dan slide presentasi

Langkah menjalankan di Google Colab:

1. Buka colab.research.google.com, lalu unggah klasifikasi_tiket.ipynb atau buka langsung dari GitHub.
2. Unggah dataset_tiket_ti.csv ke sesi Colab (ikon berkas di panel kiri).

3. Pilih Runtime > Run all. Semua pustaka yang dibutuhkan (pandas, scikit-learn, matplotlib) sudah tersedia di Colab.
4. Hasil metrik akan tampil pada keluaran sel, dan grafik disimpan sebagai berkas gambar.